

Deep learning / apprentissage profond

Cours 1 : Introduction.

Hervé Le Borgne
herve.le-borgne@cea.fr

2019-2020


Avant propos

Petit sondage

Que vous évoque le terme « *deep learning* » ?

Révélation grand public

mars 2016 : le programme AlphaGo (Deepmind, Google) bat Lee Sedol (classé 9^e dan pro) sans handicap, au jeu de Go.



Mai 2017 : AlphaGo bat Ke Jie (N°1 mondial) et prend sa retraite

(il a peut-être trouvé plus lucratif)

AlphaGo prend sa retraite du jeu de Go après avoir collé 3-0 au meilleur joueur du monde



Par Fabio, le 29 mai 2017 à 10h11 | 7 commentaires | Signaler une erreur



Avant propos

consécration en 2019 :
Prix Turing (2018)

« Pour les percées conceptuelles et techniques qui ont fait des réseaux neuronaux profonds une composante essentielle de l'informatique ».

Le prix Turing honore les pères du deep learning Yann LeCun, Yoshua Bengio et Geoffrey Hinton

GAUTIER VIOLE

PUBLIE LE 27/03/2019 À 19H00

Le Français Yann LeCun, le Britannique Geoffrey Hinton et le Canadien Yoshua Bengio, les trois pères fondateurs du deep learning, ont reçu le 27 mars le prix Turing, équivalent du Nobel d'informatique, pour leur apport à l'intelligence artificielle.



Yoshua Bengio



Geoffrey Hinton




Yann LeCun

Avant propos

Des promesses émergentes (2015-2016)

- systèmes de conduite autonomes (automobile, taxi, bus...)
- chatbots avancés



New Google AI Brings Automation to Customer Service

By Jack Clark

20 juillet 2016 à 18:00 UTC+2 Corrected 21 juillet 2016 à 19:30 UTC+2

- Adds two AI software products, rents out Oregon data center
- Company invests in cloud to compete with Amazon, Microsoft

USC ON BLOOMBERG
Market TV
Listen to Live Radio

ARTICLE SÉLECTIONNÉ DANS LA MATINALE DU 01/09/2016 > [Découvrir l'application](#)

Les villes s'intéressent de près aux minibus sans chauffeur

LE MONDE | 02.09.2016 à 09:50 • Mis à jour le 02.09.2016 à 12:21 |

Par Eric Bédout

[Abonnez-vous à partir de 1 €](#) [Réagir](#) [Ajouter](#) [Partager](#) [Tweeter](#)

C'est la grande tendance de l'été. Pour les décideurs de l'automobile et du transport, le véhicule de demain sera autonome ou ne sera pas. Tous les grands constructeurs de voitures ont leur programme, la Google Car sans conducteur sillonne les routes de Californie, Uber a démarré des tests à Pittsburgh (Pennsylvanie), Singapour fait rouler ses VTC sans chauffeur, et même Airbus travaille très sérieusement sur des projets de taxis volants sans



Avant propos

Technologie clé à court terme

Deep neural networks, une technologie clé émergente en 2016...

Gartner Identifies the Top 10 Strategic Technology Trends for 2016

Analysts Explore Top Industry Trends at Gartner Symposium/ITxpo 2015, October 4-8 in Orlando
isolated, incomplete, unavailable or unintelligible. Advances in semantic tools such as graph databases as well as other emerging data classification and information analysis techniques will bring meaning to the often chaotic deluge of information.


Advanced Machine Learning

In advanced machine learning, deep neural nets (DNNs) move beyond classic computing and information management to create systems that can autonomously learn to perceive the world, on their own. The explosion of data sources and complexity of information makes manual classification and analysis infeasible and uneconomic. DNNs automate these tasks and make it possible to address key challenges related to the information of everything trend.

DNNs (an advanced form of machine learning particularly applicable to large, complex datasets) is what makes smart machines appear "intelligent." DNNs enable hardware- or software-based machines to learn for themselves all the features in their environment, from the finest details to broad sweeping abstract classes of content. This area is evolving quickly, and organizations must assess how they can apply these technologies to gain competitive advantage.

Intérêt économique

Perspectives de croissance dans toutes les régions du monde



Avant propos

- ... Devenue une technologie indispensable en *data science*...

Cape Town, South Africa, September 20, 2017

[View All Press R](#)

Gartner Says Deep Learning Will Provide Best-in-Class Performance for Demand, Fraud and Failure Predictions By 2019

80 Percent of Data Scientists Will Have Deep Learning in Their Toolkits By 2018

Deep Learning Enables a Quantum Leap in Content Processing

Published: 29 September 2017 ID: G00327965

Analyst(s): [Alexander Linden](#)

Summary

Deep learning is one of the biggest artificial intelligence technology wonders of the past decade. Most progress is happening around text, audio and image processing. For data and analytics leaders, it will enable a quantum leap in those areas of their operations that are especially content-rich.


Avant propos

- ... Mais déjà à l'aube des premières désillusions ...



Avant propos



- N'épargne pas l'imitation / la création
- transfert de style [Gatys et al., 2015]
- *Deep dream* « force sur les motifs » [Le Monde, sept. 2015]



Avant propos

- Musique

- ▶ *EMI* (David Cope) compose « à la Vivaldi » [Le Monde, sept. 2015]
 - ★ *Emily Howell* (David Cope) fait ses propres créations
 - ★ *Shimon* (Guy Hoffman) improvise sur du jazz
- ▶ Taryn Southern sort l'album *I am AI* [Le Monde, février 2018]
 - ★ ossature de la mélodie et accords par *Amper*
 - ★ arrangement, orchestration, mixage → humains
 - ★ les morceaux pop partagent 80 % de leurs structures d'accords



Avant propos

- Commence à investir le « marché » de l'art
 - ▶ 3 étudiants (français)
 - ▶ 1 programme deep open source
 - ▶ qq heures (?) de programmation
 - ▶ → 432k\$!


PIXELS

CHRONIQUES
DES (R)ÉVOLUTIONS NUMÉRIQUES

VIE EN


Un tableau conçu par un programme d'intelligence artificielle adjugé 432 500 dollars

L'œuvre, vendue aux enchères chez Christie's, est le fruit des expérimentations d'un collectif de jeunes artistes français.

LE MONDE | 26.10.2018 à 13h27 • Mis à jour le 26.10.2018 à 13h40 |

Par Nicolas Six

Abonnez vous à partir de 1 €
 Réagir
 Ajouter
 Partager
 Tweeter



Avant propos

Technologie suscitant des craintes

- *Deep learning* → avancées majeures de l'intelligence artificielle (IA)
- Jusqu'en 2016, concernait surtout la *perception*.
- Désormais, concerne la *décision*, le diagnostic médical, la synthèse d'information (juristes, « journalistes »...)



Stephen Hawking et Elon Musk réclament l'interdiction des « robots tueurs »

« L'intelligence artificielle a atteint un point où le déploiement de tels systèmes sera – matériellement, si pas légalement – faisable d'ici quelques années, et non décennies, et les enjeux sont importants : les armes autonomes ont été décrites comme la troisième révolution dans les techniques de guerre, après la poudre à canon et les armes nucléaires. »



Avant propos : des craintes anciennes...



Guillaume Duval Alter Éco

9 hrs · 🌐

...

Les robots vont faire disparaître l'emploi...

La une de l'hebdo allemand Der Spiegel en 1964, en 1978 et en 2017 😊



Avant propos : ... Mais parfois justifiées !

- L'armée américaine plaide pour autoriser le développement des robots tueurs au cas où la Chine et la Russie le fassent...

Military.com BENEFITS NEWS VETERAN JOBS MILITARY LIFE VIDEOS DISC

Army Looking at AI-Controlled Weapons to Counter Enemy Fire

U.S. military has embraced AI, arguing that America cannot compete against potential adversaries without the futuristic technology. (U.S. Dept of Defense/Peggy Frierson)

10 Jan 2019
Military.com | By [Matthew Cox](#)

The head of U.S. [Army](#) acquisitions said Thursday that allowing artificial intelligence to control some weapons systems may be the only way to defeat enemy weapons.

sources : military.com et 01.net

Avant propos : ... Mais parfois justifiées !

- Et la chine l'a déjà fait !

Defense One

SecDef: China Is Exporting Killer Robots to the Mideast



大开放仓库 适配更多专业设备
BLK7050H A2 拥有下置大开口式设计，大角度高翻盖，高负载挂载，开放式结构，极大提高设备挂载空间。

AA FONT SIZE + PRINT ZIYAN



BY PATRICK TUCKER
TECHNOLOGY EDITOR
[READ BIO](#)

For the first time, a senior Defense official has called out Beijing for selling lethal autonomy.

China is exporting drones that it advertises as having lethal autonomy to the Middle East, Defense Secretary Mark Esper said Tuesday. It's the first time that a senior Defense official has acknowledged that China is selling drones capable of taking life with little or no human oversight.

NOVEMBER 5, 2019

sources : Defense One

Avant propos : ... Mais parfois justifiées !

- Même les secteurs les plus stratégiques sont concernés !
 - ▶ *AlphaStar* apprend 2 semaines (200 ans pour elle) → bat joueurs pros (10-1)
 - ▶ *AlphaStar* ne joue pas plus vite que les humains. Juste mieux.

L'intelligence artificielle DeepMind bat à plates coutures des joueurs pros sur Starcraft II

Par Mathieu Gruniaux
Le 25 janvier 2019

Clubic



AlphaStar Final : l'IA de DeepMind devient grand-maître sur StarCraft 2

Le dimanche 03 Novembre 2019 à 18:00 par Christian D. | 1 commentaire(s)

Source : DeepMind



AlphaStar Final, la dernière évolution de l'intelligence artificielle de DeepMind conçue pour jouer à StarCraft 2, est désormais capable de jouer en ligue grand-maître et de battre la quasi-totalité des humains.

source : GNT, 03/11/2019

source : (Clubic janvier 2019) (Le Monde, 25/01/2019)

- modélisation de longues séquences d'actions possibles, sous information imparfaite

Avant propos : ... Mais parfois justifiées !

- *SciNet* remplacera bientôt les chercheurs ?
 - ▶ Mouvements soleil + Mars vues de la Terre → IA produit équations de l'héliocentrisme
 - ▶ les équations doivent (encore) être interprétées par un humain



Une IA a « découvert » que la Terre tourne autour du Soleil : pourquoi est-ce si important ?



Par Nelly Lesage - 08 novembre 2019 - Sciences

Une intelligence artificielle est parvenue à découvrir que la Terre tourne autour du Soleil. Les scientifiques pensent que ce genre de technologie pourrait à l'avenir permettre de découvrir de nouvelles lois de la physique.

Avant propos : ... Mais parfois justifiées !

- Visages d'actrices incrustés dans vidéos pornos [Le Monde, 4 Fév. 2018]
[Motherboard, 11/12/17]
 - ▶ *DeepFake* ou *FakeApp* simples d'utilisation
 - ▶ Nombreuses victimes : Gal Gadot, Ariana Grande, Selena Gomez, Jessica Chastain, Emma Watson, Natalie Portman, Daisy Ridley...
 - ▶ Pour info : 24 milliards de *selfies* chargés sur GooglePhotos en 2015-16...

AI-Assisted Fake Porn Is Here and We're All Fucked

Du porno aux fausses informations, l'intelligence artificielle manipule désormais la vidéo

Des vidéos intégrant des visages de célébrités dans des films X pullulent en ligne à cause d'un programme accessible à tous et font débat.

LE MONDE | 04.02.2018 à 06h35 • Mis à jour le 04.02.2018 à 12h17

Avant propos : ... Mais parfois justifiées !

- Une nouvelle dimension potentielle pour les *fake news* :



Avant propos : alors, pourquoi ce cours ?

- DL est devenu une « technologie clé » du traitement de données
 - ▶ performances accrues par rapport au « ML classique »
 - ▶ actuellement ultra-dominant dans le domaine→ outil indispensable pour le **data scientist**
- L'IA est un carburant de croissance potentiel
 - ▶ des nouveaux services deviennent envisageables
 - ▶ course pour le *leadership* est devenu stratégique→ suscite l'intérêt des **décideurs** (politiques, économiques...) du monde entier
- L'IA suscite des craintes légitimes dans le grand public
 - ▶ risque de disparition de nombreux emplois
 - ▶ risques pour les libertés individuelles
 - ▶ (consommation d'énergie + matières premières non négligeable...)→ éducation au domaine utile au **citoyen**

Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Pourquoi ? Pour qui ?

- Des connaissances et niveaux de pratique différents :
 - ▶ Quelques notions par des lectures « grand public »
 - ▶ Initiation via des tutos ou des moocs
 - ▶ Pratique déjà avancée (année de césure, stages...)
- Des motivations différentes :
 - ▶ Le sujet est à la mode, pouvoir en parler en milieu professionnel
 - ▶ Pour devenir *data scientist*, c'est une technologie utile
 - ▶ Pour créer une entreprise dont le produit est basé sur des technos *deep*

Donc :

- Le cours s'adresse à *toutes* ces personnes
- Le cours concerne le *deep learning* (pas l'IA en général)
- Amphis : bases apprentissage → qq détails théoriques avancés
- Pratique : initiation en TD + (surtout) via un *projet*
- Tous les supports de cours, TD, projet sont sur *Edunao*

Évaluation

Devoir écrit sur table (50%)

- Devoir de 3h (14 février 2020), individuel.
- Documents autorisés ; ordinateur autorisé, voire nécessaire (sauf réseau !)

Projet (50%)

- Seul ou en groupe (3 max)
- Rapport sous forme d'article scientifique (~ 8 p « denses » + ref).
lien vers template article sur Edunao ou [ici](#)
- Programmes (structurés, commentés de manière pertinente...)
- À rendre le 1^{er} mars au plus tard (*strict deadline*)
- Sujet proposé ou au choix

Projet (sujets)

Plusieurs possibilités de sujet :

- 1 sujet perso, qui vous motive
- 2 sujet couplé à un autre cours (e.g vision par ordinateur)
- 3 exemples proposés : voir cours d'intro aux projets

Ils doivent comporter implémentation algorithmique, étude de paramètres/approches et son utilisation sur des cas concrets.

Anticipez

- choisissez tôt (discussion avec HLB, YLC et AP ; ou par mail)
- commencez tôt et travaillez « en tâche de fond » (calculs longs...)

Travail jugé « à la **densité** » et non « au poids ».
Expérimentez ! Synthétisez !! Visez la qualité !!!

Déroulement des séances (pour info)

① 05/12 : introduction

- ▶ généralités, historique, applications...
- ▶ → apprentissage automatique
- ▶ perceptron
- ▶ principaux frameworks
- ▶ pratique : installation framework

② 12/12 : généralités sur les réseaux de neurones

- ▶ réseaux profonds directs (MLP)
- ▶ → optimisation
- ▶ descente de gradient + rétro-propagation
- ▶ architectures des réseaux

③ 20/12 (argh !) : réseaux convolutifs


- ▶ convolution et couches convolutives
- ▶ architectures CNN classiques (classification et détection d'objets)
- ▶ *transfer learning*

Déroulement des séances

- ④ 10/01 : réseaux récurrents et récursifs
 - ▶ réseaux récurrents (RNN) et leurs limites
 - ▶ *long short term memory*, representations NLP
 - ▶ pratique [3 groupes] : application + aide au projet
- ⑤ 17/01 : régularisation
 - ▶ techniques de régularisation (dont *dropout*)
 - ▶ pratique [3 groupes] : application + aide au projet++
- ⑥ 06/02 : optimisation
 - ▶ solveurs et descente de gradient
 - ▶ momentum et autres techniques d'optimisation
 - ▶ pratique [3 groupes] : application + aide au projet++
- ⑦ 07/02 : sujets récents et prise de recul
 - ▶ espaces multimodaux, modèles génératifs...
 - ▶ le deep learning dans la presse grand public
 - ▶ éthique et deep learning
 - ▶ pratique [3 groupes] : application + aide au projet++

Partie pratique (TP/TD)

- Quatre séances en tiers de groupe (cours 4 à 7, de 15h30 à 17h)
- Pratique framework : Tensorflow + PyTorch
- Conseils et aide pour le projet



- Yannick Le Cacheux : doctorant CNAM et CEA (2017-2020) : *zero-shot learning*
- Antoine Plumerault : doctorant CentraleSupélec et CEA (2018-2021) : interprétabilité des DNN


Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Livres et ressources (avec liens URL)

- **Deep Learning book**, I. Goodfellow, Y. Bengio and A. Courville
 - ▶ Livre de 700 pages très complet ; **principale source de ce cours**
- **Neural Networks and Deep Learning**, M. Nielsen
 - ▶ Livre : 6 chapitres sur l'essentiel
- Articles scientifiques :
 - ▶ ArXiv, CVPR, NIPS, ICLR, ICMR, ICCV, ECCV...
 - ▶ *overview* : (Le Cun *et al.*, 2015) (Schmidhuber, 2015) (Bengio *et al.*, 2013)
- Cours CS231n de Stanford (Fei-Fei, Karpathy, Jonhson) et ses notes
- Cours au collège de France, Y. Le Cun
- vulgarisation deep learning sur chaîne YouTube *Science4all*
 - ▶ quelques « simplifications » aident à la compréhension
 - ▶ attention : épisodes 23 à 40 sont *très* subjectifs (utilitarisme voire scientisme...)

Principale source du cours



- 4 chapitres de base : algèbre, proba, optimisation, apprentissage
- Bases des réseaux de neurones (MLP)
- 2 chapitres de théorie avancée : régularisation, optimisation
- 2 chapitres sur réseaux fondamentaux : CNN, RNN
- 2 chapitres sur application et pratique
- 8 chapitres de sujets avancés

→ 775 pages de bonheur... 80\$ à l'achat ; **disponible en ligne**

Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Définitions(s)

Intelligence artificielle (IA ou AI)

Ensemble de théories et de techniques mises en œuvre en vue de réaliser des machines capables de simuler l'intelligence humaine [Larousse, oct 2016].

Apprentissage automatique (*machine learning*)

Science qui permet à un ordinateur d'apprendre sans être explicitement programmé [A. Samuel, 1959].


Apprentissage profond (*deep learning*)

Apprentissage automatique qui utilise un réseau de neurones artificiels composé d'un grand nombre de couches dont chacune correspond à un niveau croissant de complexité dans le traitement et l'interprétation des données. [legifrance.gouv.fr, décembre 2018]

Le deep learning n'est pas l'IA

- Confusion fréquente entre IA, ML et DL (et ce n'est pas très grave)
- Vise donc à reproduire, à l'aide de machines, des activités mentales : compréhension, perception, décision
- A la croisée de plusieurs disciplines :


- ▶ épistémologie
- ▶ psychologie cognitive et du développement
- ▶ logique
- ▶ informatique! ↔ maths appliquées



- ▶ biologie théorique, neurobiologie, éthologie
- ▶ sciences communications : langage, théorie information, sociologie des organisations

Une compétition mondiale

- 2017 – 2018 : un « plan IA » tous les mois dans le monde !



- Mais les moyens consacrés varient...

Source : [medium.com](https://medium.com/@leborgneherve/le-borgne@cea.fr), 28/06/2018



Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références



Précurseurs

- De l'automatisation à la programmation
 - ▶ Pascaline (1645) : calcul auto. mécanique
 - ▶ Orgue de Barbarie (~ XVII^e) : automatophones
 - ▶ Métier à tisser Jacquard (1801) : programmable !
- 1834 : *idée* machine analytique (Charles Babbage)
calcul auto. + programmable (→ ordinateur)
- 1843 : programmation (Ada Lovelace)
algorithme (formel); visionnaire... (→ traitement symbolique de l'information)
- 1853 : écriture algébrique logique (Georges Boole)
algèbre binaire → th. information (1938, C. Shannon) → informatique




Émergence de l'informatique

- 1880 : mécanographie, machine à cartes perforées (Herman Hollerith)
- 1936 : machine de Turing
 - ▶ modèle abstrait (rigoureux !)
d'algorithme et d'ordinateur
 - ▶ bases de l'informatique théorique
- 1943 : décodage d'Enigma par le calculateur électronique programmable *Colossus* [Tommy Flowers+Turing]
- 1945 : ENIAC est électronique, programmable et Turing-complet [John William Mauchly et John Eckert]




Première période de l'IA

- 1950 : test de Turing
 - ▶ une machine peut-elle penser/être intelligente?
 - ▶ référence = intelligence humaine
 - ▶ *test* basé sur imitation conversation humaine
- 1954 : langage Fortran [John Backus, IBM]
- 1955 : *Logic Theorist* [Newell, Simon, Shaw]
 - ▶ programme informatique démontrant des théorèmes de logique
 - ▶ conférence de Dartmouth, 1956 : IA = discipline scientifique
- 1958 : langage LISP [John McCarthy]




```
(defun factorial (n)
  "Calcule la factorielle de l'en"
  (if (<= n 1)
      1
      (* n (factorial (- n 1)))))
```



- 1959 : *general problem solver* [Herbert Simon, Cliff Shaw et Allen Newell]
 - ▶ peut résoudre tout problème formel
 - ▶ victime de l'explosion combinatoire


Les hivers de l'IA

- *Lighthill report* (1973, UK) → coupes budgétaires → premier hiver
 - ▶ la traduction en particulier est décevante (pb explosion combinatoire)
- baisse de l'AI théorique, financement des applications
- développements connexes et autonomisation des disciplines
 - ▶ traitement d'image
 - ▶ reconnaissance des formes
 - ▶ interfaces homme-machine
 - ▶ preuve de programme
 - ▶ langage de programmation modernes
 - ▶ ...
- 80's : développement commercial des **systèmes experts**
 - ▶ résolution de problèmes dans domaines restreint à partir de *règles* et de *faits* connus (« IA traditionnelle »)
- Mais systèmes experts ont succès limités et font des erreurs grossières
 - ▶ coupes budgétaires de la DARPA (1988) → second hiver




Thèse de Church Turing

- Une machine traite des entrées et produit des sorties : elle calcule !
- Une seule opération très simple à chaque étape (mach. séquentielle)
 - ▶ problème : choix de l'opération selon entrée + état interne
 - ▶ entrée suivante OU entrée précédente OU arrêt
- Un problème f est calculable si, étant donné x , une méthode comportant un nombre fini d'étapes produit $f(x)$
- [Turing, 1936] il existe des **machines universelles** (UTM) capables de simuler le comportement de n'importe quelle machine



- il existe différentes machines universelles
 - ▶ celle de Yuriï Rogozin a 6 symboles et 4 états



Thèse de Church Turing



- Il existe d'autres théories du calcul (Gödel, Church)
- Church et Turing ont montré qu'elles sont isomorphes aux UTM
- Thèse de Church Turing :
 - ▶ Tout calcul réalisable dans notre univers physique peut s'exprimer dans l'un des formalismes précédents
 - ▶ Autrement dit : tout calcul est simulable par une UTM
- La notion de *calcul par une machine* inclut de nombreux concepts
 - ▶ perception, décision, etc.

L'approche connexionniste


- 1943 : neurone artificiel (McCulloch–Pitts)
- 1958 : perceptron (Rosenblatt)
- 1969 : *Perceptrons* (Minsky, Papert)
 - ▶ montre les limites du perceptron
- 1972 : *self organising maps* (Kohonen)
- 1980 : Neocognitron (Fukushima) : (C)NN multicouche, hiérarchique
- 1982 : Hopfield networks (réseau récurrent) → relance intérêt pour NN



- 1986/1974 : rétro-propagation (...)
- 1998 : LeNet-5 (LeCun *et al.* chez AT&T)

L'approche connexionniste

Citations dans *Google Book*.



Trois «vagues» :

- 1 inspiration biologique + perceptron
- 2 back-propagation + MLP
- 3 (*deep learning*) : plus récent (« premier » livre en 2016)

Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Apprentissage automatique

Apprentissage automatique (*machine learning*)


Un ordinateur *apprend* une tâche T avec la performance P à partir d'une expérience E si ses performances pour la tâche T , mesurées par P , s'accroissent avec l'expérience E [Mitchell, 1997].

- Gérer des tâches trop difficiles à décrire/programmer explicitement
→ compréhension des principes sous-jacents de l'intelligence.
- Processus apprentissage $\neq$ tâche. Ex : on veut un robot marcheur
 - ▶ tâche T = marcher
 - ▶ Solution 1 : programmation du processus de marche
 - ▶ Solution 2 : (E) le programmer pour apprendre par test/erreur
 - ▶ Performance (P) : e.g distance parcourue

Apprentissage (automatique)

exemple « de base » : apprentissage supervisé

On souhaite qu'une machine soit capable de distinguer un chat d'un chien.



- on fournit en entrée de la machine des exemples de chiens et chats
- la machine répond aléatoirement au début (correct à $P = 0.5$)
- ajustement paramètres (**apprentissage**) pour améliorer réponses
- la machine fournit des réponses (**prédiction**) de plus en plus correctes
- à l'issue du processus, la machine répond correctement à des exemples qu'elle n'a jamais vu (**généralisation**)

Apprentissage automatique : tâches (à résoudre)

L'ordinateur dispose d'exemples d'apprentissage (échantillons) : $\mathbf{x} \in \mathbb{R}^d$.

Ex : pixels d'une image, enregistrement audio (MFCC)

- **classification** : appartenance de $\mathbf{x}$ à une catégorie parmi k , i.e estimer $f : \mathbb{R}^d \rightarrow \{1 \dots k\}$ ou $Pr(y = i | \mathbf{x}), i \in \{1 \dots k\}$.

Ex : reco d'objets, de visages, d'expressions...

- **régression** : prédiction d'une valeur numérique, i.e $f : \mathbb{R}^d \rightarrow \mathbb{R}$.

Ex : biologie, construction, trading HF...

- **transcription** : transformer des données en texte (ASCII).

Ex : OCR (image), Speech2text (parole)

- **traduction** : passage de symboles ASCII en d'autres symboles ASCII.

Ex : suédois $\rightarrow$ anglais



Apprentissage automatique : tâches (à résoudre)

- **sortie structurée** : la sortie est un vecteur à plusieurs dimension.
Ex : *pixel-wise segmentation*.
Ex : légende automatique, les mots ont une relation et doivent former une phrase valide



[Blaschko et al. CVPR 2013]

- **détection d'anomalie** : repérer un événement « anormal » (ou rare).
Ex : fraude à la carte bancaire, panne électrique

- **synthèse de données** : générer des données similaires à celles apprises.
Ex : jeux vidéo, synthèse de parole
- **débruitage** : retrouver x à partir de $\tilde{x}$ bruité i.e $P(x|\tilde{x})$

[Güçlütürk et al. Arxiv 2016]




Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 **Apprentissage supervisé**
 - **Principe et définition**
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Principe général

- On dispose d'exemples annotés (manuellement) de diverses *classes*
- La phase « hors ligne » permet d'apprendre un modèle de ces classes
- Lors de la phase « en ligne » des exemple non annotés sont soumis au modèle, qui prédit sa classe

Exemple dans le cas d'images :



NB : l'extraction de caractéristiques est la même lors des deux phases

Formalisme

- $p(\mathbf{x}, y)$ est la densité (inconnue) décrivant la distribution de probabilité de $(\mathbf{x}, y) \in \mathcal{X} \times \mathcal{Y}$, avec $\mathcal{X}$ compact de $\mathbb{R}^d$ et $\mathcal{Y}$ de $\mathbb{R}$.
 - ▶ $\mathcal{X}$: ensemble des **caractéristiques** (*features*). Ex : $\mathbb{R}^{1024}$
 - ▶ $\mathcal{Y}$: **labels**, par exemple $\{-1, 1\}$ pour problème binaire (*i.e* à 2 classes)
- on cherche à estimer l'**hypothèse** f qui donne y sachant $\mathbf{x}$
- le **coût** de se tromper est le coût (*loss*) : $L(\hat{y}, y) = L(f(\mathbf{x}), y)$
- but classification supervisée = minimiser le **risque attendu** :

$$f_0 = \min_{f \in \mathcal{F}} I[f] \quad \text{avec} \quad I[f] = \int_{\mathcal{X} \times \mathcal{Y}} L(f(\mathbf{x}), y) p(\mathbf{x}, y) d\mathbf{x} dy \quad (1)$$

$\mathcal{F}$ = espace des fonctions mesurables où $I[f]$ est défini

- **mais** f_0 ne peut être trouvée car $p(\mathbf{x}, y)$ est inconnue...

Formalisme

- f_0 ne peut être trouvée car $p(\mathbf{x}, y)$ est inconnue
- Soit un ensemble d'apprentissage $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$ qu'on suppose obtenu par tirage i.i.d selon $p(\mathbf{x}, y)$. Un estimateur du risque attendu est le **risque empirique** :

$$l_{emp}[f] = \frac{1}{n} \sum_{i=1}^n L(f(\mathbf{x}_i), y_i) \quad (2)$$

- La fonction $f_{\mathcal{D}}$ minimisant $l_{emp}[f]$ dans l'espace des hypothèses $\mathcal{F}$ est une approximation de la fonction f_0 idéale.
- Selon le coût et la famille paramétrique $\mathcal{F}$, $f_{\mathcal{D}}$ est plus ou moins représentative de f_0 .
- Accroître n améliore en général la qualité de l'estimation $f_{\mathcal{D}}$.

Fonction de coût



Le *0-1 loss* semble « naturel » en classification :

$$L(f(\mathbf{x}), y) = H(-yf(\mathbf{x}))$$

Mais H (Heavyside) est non convexe (non continue!) $\rightarrow$ optimisation NP-difficile!

On utilise des coûts $L(f(\mathbf{x}), y)$ convexes; en classification :

$$\begin{array}{ll} \text{Square loss} & (1 - yf(\mathbf{x}))^2 \\ \text{Hinge loss} & \max(0, 1 - yf(\mathbf{x})) \\ \text{Logistic loss} & \frac{1}{\log(2)} \log(1 + e^{-yf(\mathbf{x})}) \end{array}$$



Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 **Apprentissage supervisé**
 - Principe et définition
 - **Mesure des performances**
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Mesure des performances

Pour un problème binaire avec une classe d'intérêt (label +) :

Vérité \ Estimé	+	-
	+	-
+	TP	FP
-	FN	TN

- Tx classif = $\frac{TP+TN}{TP+FP+TN+FN}$
- Rappel (sensibilité) = $\frac{TP}{TP+FN}$
- Précision = $\frac{TP}{TP+FP}$

- 1-Spécificité = $\frac{FP}{TN+FP}$ (*fall-out*)
- Taux erreur = 1 - Tx classif
- Tx ratés = $\frac{FN}{FN+TP}$

Le choix de la mesure des performances **dépend de l'application visée.**

Exercice

Utiliseriez-vous le taux de classification pour un détecteur incendie ?

Exercice

Utiliseriez-vous le taux de classification pour un détecteur incendie ?

Soit un détecteur incendie répondant toujours « il n'y a pas le feu »
Sur 5 ans de fonctionnement se terminant par un incendie d'une heure, sa fiabilité (en terme de taux de classification) est :

$$\frac{5 * 365.25 * 24 - 1}{5 * 365.25 * 24} = 1 - \frac{1}{5 * 365.25 * 24} \approx 0.99998 \quad (3)$$

**Garanti 5 ans
Fiable à plus de
99,99 % !!!**

**Garanti à vie
Fiable à plus de
99,9999 % !!!**





• ... A vous de voir ...

Mesure des performances agrégées

Interprétation en terme de recherche d'information (moteur de recherche) :

- ▶ La **précision** donne la qualité des « premières réponses »
- ▶ Le **rappel** rend compte de l'exhaustivité des résultats

Mesures dans [01],
usuellement
contradictoires !



Exercice : quelle mesure de performance ?

Vous mettez en place un moteur de recherche visuel pour des stylistes souhaitant trouver « tendances semblables » à un motif donné.

Exercice : quelle mesure de performance ?

Vous mettez en place un moteur de recherche visuel pour des stylistes souhaitant trouver « tendances semblables » à un motif donné.




- pour un moteur de recherche, la précision *paraît* toujours importante
- **mais** s'ils souhaitent bien retrouver *tous* les motifs semblables (pour s'en distinguer), ils sont en fait intéressés par le rappel (cependant, il faut les en convaincre !)
- il est préférable que toutes les réponses soient sur la « première page ». Si elle affiche N résultats, la « bonne » mesure sera *rappel@N*

Mesure des performances agrégées

Rendre compte conjointement de « mesures contradictoires » :

- Equal Error Rate (EER) : taux tel que $FP = FN$. Doit être minimum !
- Average Precision (AP) = $\int_0^1 P(r)dr$
- Mean Average Precision (mAP) = $\frac{1}{C} \sum AP_c$
- F1-measure (F1) : $\frac{2}{F1} = \frac{1}{P} + \frac{1}{R}$



n	doc	#relevant
1	588	x
2	589	x
3	576	
4	590	x
5	986	
6	582	x
7	984	
8	988	
9	578	
10	985	
11	103	
12	591	
13	772	x
14	990	

$R = \# \text{ of relevant docs} = 6$

R-Precision = $4/6 = 0.67$

- Aire sous la courbe ROC (AUC) *Sensibilité (1-spécificité)*
- R-precision : precision @ nb doc pertinents (variable selon requêtes)

Mesure des performances spécifiques

Certaines mesures sont spécifiques à des domaines.

- En reconnaissance de parole (*word error rate*) :

$$WER = \frac{\#substitutions + \#suppressions + \#insertions}{\#mots\ de\ reference} \quad (4)$$

- Résumé automatique : *Recall-Oriented Understudy for Gisting Evaluation* (ROUGE) : 5 mesures, logiciel dédié.
- Traduction : *bilingual evaluation understudy* (BLEU) : modification de la précision pour prendre en compte le caractère « verbeux » des systèmes automatiques.




Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Capacité de généralisation


Apprentissage (supervisé) en pratique

- choisir une famille de modèle paramétrique $\mathcal{F}$
- estimer les paramètres au moyen des n échantillons disponibles ($\mathcal{D}$)
- minimiser I_{emp} en apprentissage $\neq$ bonnes performances en test



- ▶ Sous-apprentissage : modèle est insuffisamment complexe pour représenter les données
- ▶ Sur-adaptation (*overfitting*) : « colle » trop aux données

Choix du modèle



- Modèle peu complexe est « loin » des données → biais
- Modèle complexe « colle » aux données d'apprentissage (seulement!)
 - ▶ sur-adaptation → mauvaise généralisation
- Selon le jeu de données, le modèle change beaucoup
 - ▶ → grande variance de la valeur des paramètres

Choix du modèle

Minimisation du risque empirique régularisé

$$f^* = \arg \min_{f \in \mathcal{F}} [I_{emp}[f] + Reg(f)] \quad (5)$$

- Minimisation du risque empirique ET « lissage » du modèle
- $\rightarrow$ pénalisation de la « complexité » du modèle
 - ▶ expression de $Reg(f)$ dépend de la famille $\mathcal{F}$
 - ▶ théorie plus rigoureuse avec la dimension de Vapnik-Chervonenkis
 - ▶ minimisation du risque structurel

Exemple : séparateur à vaste marge (linéaire) :

$$w^* = \min_w \left(\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n L_{hinge}(x_i, y_i, w) \right) \quad (6)$$

cf. cours 5

Estimation des (hyper)paramètres

On distingue trois ensembles de données :

- **Apprentissage** : données + labels $\rightarrow$ détermine paramètres modèle
- **Validation** : test algorithme avec données; mesure performances avec labels pour chaque modèle (*i.e* ensemble d'hyperparamètres) possible.
 $\rightarrow$ détermination du meilleur modèle
- **Test** : test algo paramétré par le meilleur modèle sur « Validation » : estimation des performances (science) ou en production.

Bonne pratique

Optimiser les paramètres sur l'ensemble de validation (et non de test!) est **indispensable** pour estimer proprement l'erreur de généralisation *i.e* valider scientifiquement (non suffisant).

vocabulaire (ex.) : hyperparamètres=degré de polynôme ; paramètres=coefficients polynôme

Validation croisée

Si on ne dispose «que» d'un ensemble d'apprentissage... on le coupe !

- L'ensemble $\mathcal{D}_n$ est partitionné k fois (différemment pour chaque i) :

$$\mathcal{D}_n^{(i)} = \mathcal{A}_i \cup \mathcal{V}_i \text{ et } \mathcal{A}_i \cap \mathcal{V}_i = \emptyset$$

Pour $i \in \{1, \dots, k\}$

- ▶ on apprend f_i sur $\mathcal{A}_i$
- ▶ on mesure l'erreur $L(f_i, \mathcal{V}_i)$ sur $\mathcal{V}_i$
- On estime le risque global par : $l_{emp} = \frac{1}{k} \sum_{i=1}^k L(f_i, \mathcal{V}_i)$

Partitionnements classiques :

- *leave-one-out* : $n - 1$ données pour $\mathcal{A}_i$ et 1 pour $\mathcal{V}_i$. On estime les $k = n$ modèles
- *k-fold* : $\mathcal{D}_n$ est partitionné en k parties. Une partie sert de $\mathcal{V}_i$ et le $k - 1$ restante pour $\mathcal{A}_i$. on estime k modèles (5 à 10 usuellement).

Validation croisée




$$Perf(global) = \frac{1}{5} \sum_{i=1}^5 Perf(train = Subset_{j \neq i}, test = Subset_i) \quad (7)$$

(meilleure) bonne pratique

Une unique séparation train/val/test (*simple holdout*) est **insuffisante** pour évaluer proprement un modèle car les perf dépendent de ce découpage. On devrait toujours utiliser une cross-validation (plus couteuse...).

Choix du modèle : Grid search


- choix des intervalles de variation des hyper paramètres
- choix d'un pas grossier d'exploration
- évaluation de chaque t -uplet d'hyper paramètres
- recommencer avec un pas plus fin dans les zones intéressantes



- très calculatoire
- peut être parallélisé

Choix du modèle : *random search*

- choix aléatoire de t -uplets des hyper paramètres
- raffinement possible dans des « zones d'intérêt »



- beaucoup plus rapide
- peut donner de meilleurs résultats en pratique
- peut être combiné avec *grid search* (pour certains hyper paramètres)

Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Modèle de neurone formel

- Proposé par Mc Culloch (neurophysiologiste) et Pitts (mathématicien) en 1943

McCulloch, W. S., Pitts, W., A Logical Calculus of the Ideas Immanent in Nervous Activity, Bulletin of Mathematical Biophysics, vol. 5, pp. 115-133, 1943


- Inspiré des propriétés des neurones biologiques issues d'observations neurophysiologiques et anatomiques



Walter Pitts et Warren McCulloch

Le neurone biologique (simplifié!)

- reliés par des « fibres conductrices »
 - ▶ *dendrites* = entrées (~ 7000 par neurone)
 - ▶ *axone* = sortie (unique)
- jonctions = *synapses*
 - ▶ contiennent un espace « vide » bloquant le signal électrique
 - ▶ un signal en entrée provoque l'émission de *neuro-médiateurs* (chimiques)
 - ▶ ces substances se fixent sur des récepteurs de l'autre côté de l'espace inter-synaptique.
 - ▶ Quand suffisamment de molécules se sont fixées, un signal électrique est émis




Résumé



intégration temporelle → dépassement de seuil → transmission

Le neurone biologique : quelques chiffres

- environ 85 à 100 milliards (10^{11}) dans le cerveau humain
 - ▶ et $5 \cdot 10^8$ dans l'intestin !
- nombre variable selon les espèces
 - ▶ 302 chez *Caenorhabditis Elegans* : suffisant pour se déplacer, manger, se reproduire (et buller devant Hanouna)
- le corps (péricaryon, soma) mesure 5 à $120 \mu m$
- axone : diamètre de 1 à $15 \mu m$; longueur de quelques *mm* à *1m*
- il est « un peu » plus compliqué en pratique...




Espèce	Nombre de neurones
C. Elegans	302
Escargot	11 000
Cafard	1 000 000
Grenouille	16 000 000
Souris	75 000 000
Chat	1 000 000 000
Chimpanzé	7 000 000 000
Homme	85 000 000 000




Modèle de neurone formel

[Mc Culloch et Pitts, 1943]



- original : entrées binaires (0/1) pondérées (synapses), sommées (accumulation) puis comparées à un seuil (transmission)
- généralisable x, w dans $\mathbb{R}^n$: $o = \varphi(\sum_{i=1}^n w_i x_i)$ avec ϕ non-linéaire
- fonction d'activation à seuil ($H_\theta = \text{Heaviside}$)
 - ▶ Si la somme dépasse un seuil θ la sortie vaut 1
 - ▶ Sinon, elle vaut 0. En 0 elle vaut 1 (ou 1/2)
- autres fonctions d'activation non linéaires possibles



Neurone formel et logique

- Le neurone formel permet de réaliser des calculs logiques élémentaires
- Considérons $(H(w_0 + w_1 x_1 + w_2 x_2))$:
 - deux entrées binaires x_1 et x_2
 - et des poids unitaires ($w_1 = w_2 = 1$)
 - une activation à seuil (Heaviside) w_0 avec $H(0) = 1$
- Selon la valeur du seuil, on peut réaliser différentes fonctions logiques :
 - $-1 \leq w_0 < 0$: fonction OU
 - $-2 \leq w_0 < 1$: fonction ET
 - Si $w_0 \geq 0$, on force à 1 ; si $w_0 < -2$ on force à 0
- Similairement, un neurone à 1 entrée peut réaliser Identité et NOT.

x_1/x_2	0	1
0	$H(w_0)$	$H(1 + w_0)$
1	$H(1 + w_0)$	$H(2 + w_0)$

Mais :

Les poids du neurone formel sont réglés « à la main »...

Règle de Hebb

- Règle d'apprentissage proposée par Donald Hebb en 1949
- « des neurones qui stimulent en même temps, sont des neurones qui se lient ensemble. » (« *cells that fire together, wire together* »)
- $\Rightarrow$ lorsque deux neurones sont excités conjointement, il se crée ou renforce un lien les unissant.




$$\Delta w_i = \epsilon x_i y \quad (8)$$

- Le i -ème poids synaptique w_i a une modification Δw_i proportionnelle au produit de la i -ème entrée x_i et de la sortie y
- Le coefficient de proportionnalité ϵ est le taux d'apprentissage (*learning rate*)


Perceptron

- Classifieur linéaire binaire (2 classes) [Frank Rosenblatt, 1958].
- Règle de Hebb appliquée au neurone formel.
- Problème : apprendre un séparateur linéaire $(\mathbf{w}, b) \in \mathbb{R}^d \times \mathbb{R}$
 - ▶ Ensemble d'apprentissage $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$
 - ▶ Représentation canonique : $\mathbf{x} \leftarrow [1, \mathbf{x}^T]^T$. Ainsi $\mathbf{w} \leftarrow [b \ \mathbf{w}] \in \mathbb{R}^{d+1}$
 - ▶ label $y \in \{-1, 1\}$ et une prédiction est $\text{sign}(\mathbf{w}^T \mathbf{x})$
 - ▶ prédiction correcte si $y \cdot \mathbf{w}^T \mathbf{x} > 0$
 - ▶ Le but de l'apprentissage est de trouver le meilleur $\mathbf{w}$
- Solution : perceptron



- ▶ « réseau de neurones » à... 1 neurone !
- ▶ entrées binaires (0/1) ou continues ($\in \mathbb{R}$)
- ▶ paramètres = poids ($\mathbf{w}$) et un biais (b)
 - ★ $\mathbf{w}$: hyperplan $\rightarrow$ séparateur linéaire
 - ★ b : seuil (translation hyperplan) $\rightarrow$ décision affine

interprétation géométrique



- Deux classes : $y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$ (ici biais $b = w_0$)
- Frontière $y(\mathbf{x}) = 0$ perpendiculaire à $\mathbf{w}$
- Chaque classe = 1/2 plan
- Distance (signée) de $\mathbf{x}$ à frontière est $\frac{y(\mathbf{x})}{\|\mathbf{w}\|}$
- En représentation canonique ($[1 \ x_1 \ x_2]^T$), l'hyperplan passe par l'origine dans espace 3D pour la figure ci-dessus

Perceptron


Apprentissage du perceptron « en ligne » a.k.a « règle du perceptron »

- Ensemble d'apprentissage $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$ avec $y_i \in \{-1, 1\}$
- Initialisation aléatoire (ou 0) de $\mathbf{w}$
- Répéter sur tous les exemples d'apprentissage :
 - ▶ Calculer la sortie $\hat{y}_i = \varphi(\mathbf{w} \cdot \mathbf{x}_i)$ avec $\varphi(.) = \text{sign}(.)$
 - ▶ Si erreur i.e $y_i \hat{y}_i \leq 0$:
 - ★ mise à jour des poids : $\mathbf{w} \leftarrow \mathbf{w} + y_i \mathbf{x}_i$
 - ▶ (ou : $\mathbf{w} \leftarrow \mathbf{w} + \frac{1}{2}(y_i - \hat{y}_i)\mathbf{x}_i$ « dans tous les cas », sans condition)

- Si erreur, poids $\mathbf{w}$ modifiés dans la direction corrigeant l'erreur
- Si $y_i \in \{0, 1\}$ et $\varphi(.) = \text{heavyside}(.)$ on peut utiliser :

$$\mathbf{w} \leftarrow \mathbf{w} + (y_i - \hat{y}_i)\mathbf{x}_i$$

- il faut mélanger les exemples : ne **pas** grouper les +1 puis les -1



Red points belong to the positive class,
blue points belong to the negative class

(haut-gauche → haut droite → bas gauche → bas droite)

Perceptron

Apprentissage du perceptron « batch »

- Ensemble d'apprentissage $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$
- Initialisation aléatoire (ou 0) de $\mathbf{w}$
- Répéter jusqu'à $|\delta| < \epsilon$
 - ▶ $\delta \leftarrow (0, 0, \dots, 0)$
 - ▶ Pour $i = 1$ à n
 - ★ Calculer la sortie $\hat{y}_i = \varphi(\mathbf{w} \cdot \mathbf{x}_i)$
 - ★ Si erreur ($y_i \hat{y}_i \leq 0$) :

$$\delta \leftarrow \delta + y_i \cdot \mathbf{x}_i$$
 - ▶ $\delta \leftarrow \delta / n$
 - ▶ $\mathbf{w} \leftarrow \mathbf{w} + \eta \delta$
- η est le taux d'apprentissage (*learning rate*)
- En pratique, il vaut mieux le faire décroître en cours d'apprentissage

Perceptron

- Approche d'apprentissage : le match !

« en ligne »	« batch »
un exemple à la fois : correction $\mathbf{w}$ immédiate	tous les exemples à la fois : accumulation des erreurs et correction $\mathbf{w}$ globale
sensible à l'ordre → labels mélangés	indépendant de l'ordre → peu importe ordre labels
capacité mémoire et calculatoire nécessaire limitée	capacité mémoire et calculatoire nécessaire maximale
descente de gradient stochastique	« vraie » descente de gradient


- Les deux approches/modes :
 - ▶ n'aboutissent **pas forcément à la même solution !**
 - ▶ n'ont **pas le même coût** (mémoire, calculs)

Perceptron

Une application de la **descente de gradient** (v. cours 2). Étant donné

- Ensemble d'apprentissage $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$
- Une fonction de coût $J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n L(\mathbf{w} \cdot \mathbf{x}_i, y_i)$

On souhaite trouver $\mathbf{w}^*$ qui minimise $J(\mathbf{w})$



Perceptron

Une application de la **descente de gradient** (v. cours 2).

Descente de gradient

- initialiser w aléatoirement (ou à 0)
- Calculer le gradient (dérivée multidimensionnelle) $\nabla_w J$
- Répéter jusqu'à convergence : $w \leftarrow w - \eta \nabla_w J$

Quelle fonction de coût J ?

Perceptron

Quelle fonction de coût J ?

- 0/1 Loss



- ▶ $L_{0/1} = H(-wxy)$ avec H (Heavyside) : $L_{0/1}$ nul si $\text{sign}(\mathbf{w}^T \mathbf{x}) = y$

- ▶ $J_{0/1} = \frac{1}{n} \sum_{i=1}^n L_{0/1}(\mathbf{w}, \mathbf{x}_i, y_i)$

- Règle du perceptron ($\sim$ hinge loss)

- ▶ $J_{\text{perceptron}} = \frac{1}{n} \sum_{i=1}^n \max(0, -y_i \mathbf{w} \mathbf{x}_i)$

- ▶ $\max(0, -y_i \mathbf{w} \mathbf{x}_i)$ donne une « confiance sur l'erreur » (0 si OK)



$\Rightarrow$ région solution plate *versus* « convexe »

Remarques « finales » sur le perceptron

- perceptron = NN 1 couche = séparateur linéaire 2 classes
- procédures d'apprentissage par descente de gradient (stochastique)
- un **théorème** assure la convergence si les données sont linéairement séparables
- dans les cas non séparables
 - ▶ la procédure ne s'arrête pas → on définit un nombre de boucles a priori (+ seuil erreur)
 - ▶ on peut aussi voter [Freud et Shapire, 1998] :

```

Let  $w_0 = (0,0,0, \dots, 0)$ 
 $c_0 = 0$ 
repeat
  Take example  $i : (x_i, y_i)$ 
   $u_i \leftarrow w_n \cdot x_i$ 
  if  $y_i \cdot u_i \leq 0$ 
     $w_{n+1} \leftarrow w_n + y_i x_i$ 
     $c_{n+1} = 0$ 
     $n = n + 1$ 
  else
     $c_n = c_n + 1$ 

```

Décision par vote pour un x en test :

$$\text{sign} \left(\sum_{n=0}^N c_n \text{sign}(w^T x) \right) \quad (9)$$

- c_n = mesure de confiance sur les hyperplans appris itérativement

Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé

- Principe et définition
- Mesure des performances
- Généralisation et choix des modèles


- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

A quoi ça sert ?

- Beaucoup (vraiment beaucoup) de choses...
- Encore limité pour certains domaines
 - ▶ nécessite beaucoup de données (pb du « small data »)
 - ★ diagnostique maladies rares
 - ★ archéologie (hiéroglyphes maya [Roman-Rangel & Marchand-Maillet, 2015, 2016]) et documents historiques
 - ▶ « nécessite » un matériel spécifique (GP-GPU)
 - ★ largement démocratisé... (même en embarqué)
 - ★ distinguer apprentissage (coûteux !) et déploiement
 - ★ il faut parfois faire avec l'existant
- Il ne faut pas jeter les autres approches
(surtout en pratique)
- Ce n'est pas l' α et l' Ω de l'IA
 - ▶ *deep-gaga...*
 - ▶ cela simule l'intelligence humaine par *certain*s aspects **limités**

“When you're fundraising, it's AI. When you're hiring, it's ML. When you're implementing, it's logistic regression.”

- le deep est **inspiré** du cerveau humain comme les ailes d'avion sont inspirées des ailes d'oiseaux
- l'inspiration n'est pas plus celle d'un cerveau humain que d'un cerveau de limace
- l'état de l'art est très loin des capacités d'un cerveau animal



(même lui, si, si...)



Yann LeCun

3 hrs · 🌐

"Neural networks copy the human brain." I cringe every time I read something like this the press. It wrong in multiple ways.

First, neural nets are loosely "inspired" by some aspects of the brain, just as airplanes are loosely inspired by birds.

Second the inspiration doesn't come from the human brain. It comes from "any" animal brain: monkey, cat, rat, mouse, bird, fish, fruit fly, aplysia sea slug, all the way down to *Caenorhabditis elegans*, the 1mm-long roundworm whose brain has exactly 302 neurons.

What neural nets have in common with animal brains is: 1. they are composed of simple computing elements with multiple inputs and one output (neurons); 2. The neurons essentially compute a weighted average of their input and compare the result to a threshold; 3. They learn by modifying the strength of the connections between neurons (synapses); 4. The architecture of convolutional nets (a particular kind of neural net) is inspired by some aspects of the pattern of connections in the visual cortex of animals (e.g. small mammals). That's about it. Pretty much every other detail is different.

Saying that neural nets are copied on "the human brain" seems to suggest that they reproduce functions that are specific to humans, not found in the rest of the animal kingdom. But nothing could be further from the truth.

First, we have no idea in what way the human brain is different from other mammalian brains (except for the size). Second, the human brain isn't that different from the brains of other primates.

Third, AI researchers would be happy to build a machine as intelligent as a parrot, a crow, a rat or a cat. That would be a tremendous progress over the current state of the art.




You and 1K others

27 Comments 147 Shares

Le matériel nécessaire

- le deep learning nécessite beaucoup de calculs
- + les calculs unitaires sont simples et peuvent être parallélisés
- mise en pratique grâce au GPGPU (+ librairie NVIDIA)
 - ▶ cuDNN : *CUDA Deep Neural Network library*
 - ▶ librairie de primitives pour DNN spécialisé GPU (NVIDIA)



AlexNet training throughput based on 20 iterations.
CPU: 1x E5-2680v3 12 Core 2.5GHz. 128GB System Memory, Ubuntu 14.04

Le matériel nécessaire

- calculs « lourds » surtout en apprentissage
- matériel plus léger en déploiement (avec modèle appris)
- possibilité de systèmes embarqués (voiture, robots...)



NVIDIA Jetson TK1

- lors de la ruée vers l'or, les vendeurs de pioches se sont enrichis...

Le matériel nécessaire

- 2018 : Intel contre-attaque !
 - ▶ puce *Nervana* dédiée *deep learning*
 - ▶ marché du cloud prioritaire
- Google avait déjà sa *Tensor Processing Unit* (TPU) pour se protéger du monopole Nvidia
- Présent depuis (juillet) 2017
 - ▶ *Movidius Neural Compute Stick*
 - ▶ Peu cher, peu énergivore (1W) → embarqué
 - ▶ support Caffe, demi-précision (floats 16 bits)
- au delà du matériel, le support logiciel associé est primordial
 - ▶ optimisation (e.g CuDNN)
 - ▶ facilité d'utilisation (e.g pyTorch, Keras...)
 - ★ dont : portabilité

L'USINE DIGITALE

Intel veut mettre fin à la domination du GPU sur le deep learning

JULIEN BERGOUNHOUX | INTELLIGENCE ARTIFICIELLE, INTEL, SERVEURS ET RÉSEAUX |
PUBLIÉ LE 10 JANVIER 2018 À 07H00


INTRODUCTION Le GPU est aujourd'hui le choix par défaut pour faire du deep learning. Un état de fait qui a donné des ailes à Nvidia, doublant ses revenus en 3 ans. Mais le GPU est-il la meilleure option ? Pas selon Naveen Rao, fondateur de Nervana et désormais Corporate Vice President en charge du groupe intelligence artificielle chez Intel. La solution (matérielle et logicielle) de Nervana, 100% pensée pour l'IA, sera commercialisée en 2018, et marquera d'après lui la fin de la domination du GPU sur ce marché.



Applications

[Zhang, Isola, Efros. Colorful Image Colorization. In ECCV, 2016]


- colorisation d'image noir et blanc
- trompe les humains à 32% (couleur originale vs recolorisation)



Applications

[Andrew Owens et al., Visually Indicated Sounds, CVPR 2016]

- 922 vidéos de baguette de tambour percutant différentes matières
- apprend à reproduire le son à partir des images
- Choix « son généré » vs « vrai son » :
→ les humains choisissent le son généré à 40% (NB : hasard = 50%)



Applications

Word Lens de *Quest Visual*. Intégré à Google Translate en 2015


Traduction automatique de l'environnement augmenté

- détection de lettre
- OCR
- détection de la langue
- traduction automatique
- réalité augmentée (sur un téléphone)



Applications

- Détection et reconnaissance d'objets :
 - ▶ détecter boîte englobante
 - ▶ labelliser le contenu correctement
 - ▶ on peut même labelliser au niveau pixel (segmentation sémantique)



- Traitement automatique des langues

Ex : co-référence

- ▶ *Le voisin* de mon cousin l'a arnaqué, **il** est en prison
- ▶ Le voisin de *mon cousin* l'a dénoncé, **il** est en prison

Applications

Apprentissage de syntaxe, style et ponctuation

- Shakespeare
- articles wikipedia (avec les balises)
- Algèbre géométrique en LaTeX
- Code source du noyau Linux (ne compile pas!)
- Prénoms de bébé
- Harry Potter (T1 à 4 ds LSTM → 1 chapitre)

```

/*
 * Increment the size file of the new incorrect UI_FILTER group information
 * of the size generatively.
 */
static int indicate_policy(void)
{
    int error;
    if (fd == MARK_EPT) {
        /*
         * The kernel blank will could it to userspace.
         */
        if (ss->segment < max_total)
            unlock_graph_and_set_blocked();
        else
            ret = 1;
        goto bail;
    }
    segaddr = in_SB(in_addr);
    selector = seg / 32;
    setup_works = true;
    for (i = 0; i < blocks; i++) {
        seq = buf[i+1];
        bpf = bd->bd.next + i * search;
        if (fd) {
            current = blocked;
        }
    }
    rw-name = "GetLibregs";
    bprm_self_clear(&iv-version);
    regs->new = blocks[(BPF_STATS <= info->hisoridex) | PMR_CLOBATHING_SECONDS < 12];
    return seqtable;
}

```

"The Malfoys!" said Hermione.

Harry was watching him. He looked like Madame Maxime. When she strode up the wrong staircase to visit himself.

"I'm afraid I've definitely been suspended from power, no chance — indeed?" said Snape. He put his head back behind them and read groups as they crossed a corner and fluttered down onto their ink lamp, and picked up his spoon. The doorbell rang. It was a lot cleaner down in London.

Hermione yelled. The party must be thrown by Krum, of course.

Rudi Levette Berice Lussa Hany Mareanne Chrestina Carissy Marylen Hammine Janyte Marlise Jacacrie
 Hendred Romand Charienna Nenotto Ette Dorane Wallen Marly Darine Salina Elvyn Ersia Maralena Minoria
 Ellia Chamrin Antley Nerillie Chelon Walnor Evena Jerly Stachon Charisa Allisa Anatha Cathanie Geetra Alexie
 Jerin Cassen Herbert Cossie Velen Daurenge Robester Shermond Terisa Licia Roselen Ferine Jayn Lusine
 Charyanne Sales Sanny Resa Wallon Martine Merus Jelen Candica Wallin Tel Rachene Tarine Ozilia Kefia
 Shanne Amande Karella Roselina Alessia Chasty Deland Berther Geamar Jackelin Mellisand Sagdy Nenc
 Lessie Rasemy Guen Gavi Milea Anneda Margoris Janin Rodelin Zeanna Elyne Janah Ferzina Susta Pey
 Castina

Source : Karpathy et Max Deutsch

Applications

- Visual Question answering [Aishwarya Agrawal *et al.*, ICCV 2015]
 - ▶ une question en langage naturel
 - ▶ une image contenant des éléments de réponse
 - ▶ → réponse (simple) en langage naturel



What color are her eyes?
What is the mustache made of?



How many slices of pizza are there?
Is this a vegetarian pizza?



Is this person expecting company?
What is just under the tree?



Does it appear to be rainy?
Does this person have 20/20 vision?

→ voir suite du cours...

Applications

- aide (accélère) les enquêtes en sciences sociales et marketing



Researchers Using GPUs to Monitor Underage Drinking on Instagram

November 4, 2015


Instagram could offer a novel way of monitoring the drinking habits of teenagers.

Using photos and text from Instagram, a team of researchers from the University of Rochester has shown that this data can not only expose patterns of underage drinking more cheaply and faster than conventional surveys, but also find new patterns, such as what alcohol brands or types are favored by different demographic groups. The researchers say they hope exposing these patterns could help develop effective intervention.

Monitoring Adolescent Alcohol Use via Multimodal Analysis in Social Multimedia

Ran Pang, Agustin Baretto, Henry Kautz, and Jiebo Luo
University of Rochester
Rochester, NY 14627
{rpang, abaretto, kautz, jluo}@cs.rochester.edu

- données *Instagram*
- analyse des visages → profil (*age, gender, and race*)
- analyse des comportement de consommation alcooliques des 16-24 ans (41% des usagers Instagram)
- liens types/marques d'alcool et différents groupes démographiques



Applications

surveille les réseaux sociaux...
(pour le meilleur et pour le pire)


États-Unis : l'intelligence artificielle pour prévenir les prochaines tueries



par Yohan Demeure, rédacteur scientifique · 1 mars 2019, 1 h 29 min

En Chine, la vie sous l'oeil inquisiteur des caméras

ENQUÊTE LES ECHOS WEEK-END - Dans l'empire du Milieu, les caméras de reconnaissance faciale sont partout. L'intelligence artificielle permet ainsi de retrouver des criminels en fuite ou de payer ses achats en un clin d'oeil. Mais aussi d'étouffer toute dissidence.



Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 Conclusion
- 9 Références

Principaux frameworks

- Des frameworks intégrés facilitent la manipulation des réseaux profonds :
 - ▶ implémentation bas niveau des modules élémentaires
 - ▶ gestion du matériel (CPU/GPU)
- Deux dominant largement : **Tensorflow** et **PyTorch**
- D'autre sont :
 - ▶ obsolètes : theano, caffe, caffe2 (→ pytorch), torch (lua)
 - ▶ promus par des plateformes : CNTK (microsoft) ou pour d'autres langages que python : MXNet (Apache→ AWS), DL4J (java)
 - ▶ de « simples API » : **keras** basé sur TF, CNTK... Swift (S4TF) sur TF pour Mac/iOS, Gluon sur MXNet, Sonnet sur TF, *fast.ai* sur PyTorch...




PYTORCH

sept. 2019 : Keras obsolete

Keras 2.3.0 est la dernière
release majeure : F. Cholet
conseille de passer à TF 2.0

Tensorflow

- framework de prédilection de Google/Deepmind
- nombreux tutoriaux, grande communauté → bcp ressources
- très facile à installer (e.g virtualenv)
- interaction via wrapper Python + module `tf.keras`
- visualisation des réseaux, résultats, etc. via **Tensorboard**
- principe = execution d'un graph de calcul statique
 - ▶ très efficace (backend C++) mais peu convivial
 - ▶ “eager mode” interactif (et assez efficace), par défaut dans TF 2.0



PyTorch

- framework de prédilection de Facebook (NYU)
- très facile à installer sous Linux (ou MacOS X)
- communauté très active (en vision en particulier), nombreux tutoriaux
- API python développée en 2017 : Torch (lua) → **PyTorch**
 - ▶ très facile d'utilisation et très lisible (graph dynamique)
- visualisation via `torch.utils.tensorboard`
- efficace : backend C/CUDA



Quel framework choisir ?

- C'est **votre** choix
- Le même que celui de votre collègue/équipe (qui le connaît déjà)
 - ▶ il pourra vous aider (valeur +++)
 - ▶ vous pourrez reprendre ses programmes directement
 - ▶ vous aurez un sujet de discussion éternel au coin café
- Si vous ne savez (vraiment) pas que choisir :
 - ▶ **Tensorflow** est très populaire (sur github), avec t. bon tutos (et est facile d'utilisation avec interface `tf.keras`)
 - ▶ **PyTorch** a une popularité croissante et est très lisible/intuitif
- Liste plus complète sur WP:en:Comparison of deep learning software

Dans tous les cas :

- il ne peut pas être mauvais d'en pratiquer plusieurs
- la conversion des modèles/méthodes est possible (mais chronophage)

Standardisation des modèles deep

- *Open Neural Network Exchange* (ONNX) : standard de modèle deep pour favoriser l'interopérabilité
- Lancé en septembre 2017 par Facebook (→ caffe2, pyTorch) et Microsoft (CNTK)
- Vite rejoint par :
 - ▶ acteur cloud : AWS (→ MXNet)
 - ▶ acteurs Hardware : AMD, ARM, Huawei, IBM, Intel, Qualcomm
 - ▶ acteur GPU : NVIDIA
 - > *tensorRT* pour portabilité GPU (HPC → embarqué)
- mais toujours « snobé » par Google
 - ▶ il existe néanmoins un connecteur Tensorflow (par des ingénieurs IBM!)



Installation Tensorflow

Nombreuses méthodes d'installation données sur le site

- **Pip install**: Install TensorFlow on your machine, possibly upgrading previously installed Python packages. May impact existing Python programs on your machine.
- **Virtualenv install**: Install TensorFlow in its own directory, not impacting any existing Python programs on your machine.
- **Anaconda install**: Install TensorFlow in its own environment for those running the Anaconda Python distribution. Does not impact existing Python programs on your machine.
- **Docker install**: Run TensorFlow in a Docker container isolated from all other programs on your machine.
- **Installing from sources**: Install TensorFlow by building a pip wheel that you then install using pip.

- méthodes plus ou moins « intrusives » dans le système existant
- et plus ou moins aisées à mettre en œuvre
- ou alors utiliser en ligne sur **Google Collab**

Installation Tensorflow

- Installation virtualenv facile modulo :
 - ▶ driver nvidia (via les dépôts)
 - ▶ CUDA et CuDNN à avant l'installation de TF
 - ▶ Selon version de TF, certaines version minimales requises
 - ▶ très bien expliqué sur le site de Tensorflow et NVIDIA...
- Installation conda inclut versions CUDA/CuDNN appropriées
 - ▶ TF propose conda + pip → bof...
 - ★ voir ici comment le faire et ici pourquoi il ne faut pas
 - ★ Il y a de grandes chances que ça plante à cause de versions incompatibles de tensorflow_gpu, python, CUDA, CuDNN, compilateur, etc.
 - ▶ → Utiliser la version supportée par la communauté :

Installer TF avec conda

```
conda create -n tf_gpu tensorflow-gpu
```

Installation PyTorch

- multiples méthodes indiquées sur le site
 - ▶ indique les quelques commandes à utiliser selon configuration

PyTorch Build	Stable (1.0)			Preview (Nightly)	
Your OS	Linux		Mac		Windows
Package	Conda		Pip		LibTorch
Language	Python 2.7	Python 3.5	Python 3.6	Python 3.7	C++
CUDA	8.0	9.0		10.0	None
Run this Command:	conda install pytorch torchvision -c pytorch				

- Méthode conseillée via conda (contient CUDA et CuDNN adapté!)
- Très facile via virtualenv aussi
 - ▶ modulo l'installation préalable de CUDA et CuDNN...

Plan

- 1 Avant propos
- 2 Organisation du cours
 - Le cours
 - Références externes
- 3 Intelligence artificielle
 - IA : historique
 - Apprentissage automatique
- 4 Apprentissage supervisé
 - Principe et définition
 - Mesure des performances
 - Généralisation et choix des modèles
- 5 Du neurone formel au perceptron
- 6 Les applications du deep learning
- 7 Deep Learning en pratique
- 8 **Conclusion**
- 9 Références

Conclusion

Vous avez (ré)appris ou (re)vu :

- Que le deep learning est à la mode
- Une histoire rapide de l'IA
 - ▶ D'où vient le deep learning
 - ▶ Quels sont les liens avec le reste de l'IA
- **Apprentissage supervisé**
 - ▶ les bases et principes fondamentaux → à maîtriser !
 - ▶ importance de bien mesurer les performances
 - ▶ la problématique centrale de la généralisation
- Premier algorithme d'apprentissage : le **perceptron**
- Exemples d'applications du *deep learning*
- Principaux frameworks de *deep learning*

Pour les prochains cours

- Maîtrise absolue de l'apprentissage supervisé
- Revoir le perceptron
 - ▶ on reviendra sur la plupart de ses principes
 - ▶ le *deep learning* est (en partie) un « gros perceptron »
- Installer votre framework préféré
 - ▶ Installer Tensorflow ou PyTorch si vous ne savez pas
 - ▶ les exercices (cours 4 à 7) seront corrigés en Tensorflow et PyTorch
- Commencer votre projet !
 - ▶ On peut pratiquer en partie en « boîte noire »
 - ▶ L'essentiel de la théorie de base sera vue aux cours 2 (MLP) et 3 (CNN)
 - ▶ Plusieurs tâches à faire :
 - ★ choisir et définir son projet (expériences, hypothèses...)
 - ★ récupérer les données
 - ★ manuscrit « à vide » + description projet + description expériences

Références

- Mitchell, T. M. (1997). Machine Learning. McGraw-Hill, New York
- Roman-Rangel, E., Can, G., Marchand-Maillet, S., Hu, R., Gayol, C. P., & Krempel, G., et al. (2016). Transferring Neural Representations for Low-dimensional Indexing of Maya Hieroglyphic Art. In 3rd Workshop on Computer Vision for Art Analysis (VISART-ECCV 2016), Amsterdam, NL.
- Roman-Rangel, E., & Marchand-Maillet, S. (2015). Shape-based detection of Maya hieroglyphs using weighted bag representations. Pattern Recognition, 48(4), 1161-1173.
- Andrew Owens, Phillip Isola, Josh McDermott, Antonio Torralba, Edward Adelson, William Freeman. Visually Indicated Sounds CVPR 2016.
- Aishwarya Agrawal, Jiasen Lu, Stanislaw Antol, Margaret Mitchell, C. Lawrence Zitnick, Dhruv Batra, Devi Parikh (2015) Visual Question Answering, ICCV 2015

Colorisation des images

- Gustav Larsson, Michael Maire, and Gregory Shakhnarovich. Learning Representations for Automatic Colorization. In ECCV 2016.
- Satoshi Iizuka, Edgar Simo-Serra, and Hiroshi Ishikawa. Let there be Color! : Joint End-to-end Learning of Global and Local Image Priors for Automatic Image Colorization with Simultaneous Classification. In SIGGRAPH, 2016
- Zhang, Isola, Efros. Colorful Image Colorization. In ECCV, 2016